

Comment créer des régresseurs de calendrier ?

Tanguy

Divergence entre regresseurs Insee (SAS) et RJD

Couleur des paragraphes

Dans la suite, les paragraphes verts sont des exemples numériques.

Les paragraphes bleus font référence à ce qui se passe en pratique (sur **SAS** ou **rjd3modelling**).

Notation

Dans la suite :

- i désigne le jour de la semaine
- j ou $mois_j$ désigne le numéro du mois de l'année
- t désigne la date à laquelle on se trouve (croisement de j et de l'année)

Préparation du calendrier

Les formules appliquées ici sont expliquées dans la seconde partie du document.

- On compte les jours ($NbDays$ est le nombre total de jour du mois) : Day_i est le nombre de jour n°i dans le mois (Day_1 est le dimanche, Day_2 le lundi, ... Day_7 est le samedi)
- On compte les jours fériés Off_i est le nombre de jour férié tombant un jour n°i dans le mois (Off_1 pour tous les dimanches, Off_2 les lundis, ... et Off_7 les samedis)
- On distingue alors jours In et jours Off (selon fériés et vacances). En France la liste des jours Off est :
 - 1er de l'an (1er janvier)
 - Lundi de Pâques
 - Jeudi de l'ascension
 - Lundi de pentecôte
 - Fête du travail (1er mai)
 - Armistice de 1945 (8 mai) mais uniquement depuis 1982
 - Fête nationale (14 juillet)
 - L'assomption (15 Août)
 - Toussaint (1 novembre)
 - Armistice de 1918 (11 novembre)
 - Noël (25 décembre)
 - les différents ponts (les lundi et vendredi à chaque fois qu'il y a un mardi ou un jeudi de férié) **ne sont pas considérés comme jours fériés**

Ainsi on peut définir les jours ouvrables $In_i = Day_i - Off_i$ pour i entre 1 et 7.

- On crée les jours TD (tradings days) comme contrast par rapport à un référence (généralement le dimanche) : $TD_i = Day_i - Day_1$ pour i entre 2 et 7. Par abus de notation, des fois i parcourt $[1, 6]$ et non $[2, 7]$ et alors 1 désigne le lundi et 6 le samedi.

- On crée la variable WD (working days) qui calcule un nombre moyen de jours travaillé (en contraste)

$$WD = \left(\sum_{i=2}^6 Day_i \right) - \frac{5}{2} \times (Day_1 + Day_7)$$

On applique la formule plus générale :

$$reg_i = group_i - group_0 \times \frac{\#group_i}{\#group_0}$$

avec ici $i = 1$ et $group_1 = 2, 3, 4, 5, 6$ et $group_0 = 1, 7$

- On crée les “Working week-days” = jours ouvrables (TD), en opposition les “Publics Holydays” (PH) et les “Weekday contrast” (Weekdays) :

$$TD = \sum_{i=2}^6 In_i$$

$$PH = \sum_{i=2}^6 Off_i$$

$$Weekdays = TD - \frac{5}{2} \times (PH + Day_1 + Day_7)$$

Ces variables s’appuient sur la structure de REG1 (lundi au vendredi contre samedi et dimanche).

Retrait des moyennes de long-terme

- On va calculer les moyennes de long-terme pour les variables Day_i et les Off_i . Ces moyennes se calculent mois par mois :

$$mean_Day_{i,mois_j} = \sum_{annees} Day_{i,mois_j}$$

avec i l’indice du jour de la semaine entre 1 et 7 et $mois_j$ le numéro du mois entre 1 et 12.

$$mean_Off_{i,mois_j} = \sum_{annees} Off_{i,mois_j}$$

avec i l’indice du jour de la semaine entre 1 et 7 et $mois_j$ le numéro du mois entre 1 et 12

- On peut ensuite recalculer de nouvelles variables :

$$Day_{i_corr} = Day_i - mean_Day_i,$$

$$Off_{i_corr} = Off_i - mean_Off_i,$$

$$In_{i_corr} = Day_{i_corr} - Off_{i_corr},$$

Ainsi que toutes les autres variables présentées précédemment avec les nouveaux Day_{i_corr} , Off_{i_corr} et In_{i_corr} .

Remarques : Pour les régresseurs calculés par *rjd3modeling*, on ne retire pas les mêmes éléments :

$$In_{i_corr_rjd} = In_i + mean_Off_i$$

Calcul des variables de regresseurs à partir des groupes

Présentation des différents jeux de régresseurs Au total, on compte généralement 5 jeux de régresseurs. Un jeu de régresseur est composé d'un ensemble de groupe. Chaque groupe contient des types de jours :

- le jeu REG1 créé 2 groupes de jours :
 - G_1 = jours ouvrables
 - G_0 = les autres
- le jeu REG2 créé 3 groupes de jours :
 - G_1 = jours ouvrables (sauf samedi)
 - G_2 = les samedis ouvrables
 - G_0 = les autres
- le jeu REG3 créé 3 groupes de jours :
 - G_1 = les lundis ouvrables
 - G_2 = jours ouvrables (sauf lundi et samedi)
 - G_3 = les samedis ouvrables
 - G_0 = les autres
- le jeu REG5 créé 3 groupes de jours :
 - G_1 = les lundis ouvrables
 - G_2 = les mardis ouvrables
 - G_3 = les mercredis ouvrables
 - G_4 = les jeudis ouvrables
 - G_5 = les vendredis ouvrables
 - G_0 = les autres
- le jeu REG6 créé 7 groupes de jours :
 - G_1 = lundi ouvrables
 - G_2 = mardi ouvrables
 - G_3 = mercredi ouvrables
 - G_4 = jeudi ouvrables
 - G_5 = vendredi ouvrables
 - G_6 = samedi ouvrables
 - G_0 = les autres

Ouvrable									
REG	Lundi	Mardi	Mercredi	Jeudi	Vendredi	Samedi	Dimanche	Lundi	Mardi
REG1									
REG2									
REG3									
REG5									
REG6									

Calculs des jeux de régresseurs Nous allons ensuite créer les regresseurs de calendrier comme variable de contraste par rapport à une référence. On prend généralement le groupe 0 comme groupe de référence. Ainsi pour un jeu de régresseur qui contient n groupes, on calcule $n - 1$ régresseurs.

Afin d'introduire de la comparabilité entre les groupes et avoir de l'homogénéité dans nos contrastes, nous allons pondérer le groupe 0 à la hauteur de la répartition du nombre de jour entre le groupe i et le groupe 0.

Nos régresseurs s'écrivent ainsi :

$$REG_{n_AC_k} = REG_k - \omega_k REG_0$$

avec ici n qui vaut 1, 3, 5, 6, ... et k entre 1 et n .

De manière générale, les ω_k sont calculés à partir de la taille des groupes :

$$\omega_k = \frac{\#group_k}{\#group_0}$$

- Pour les jeux de régresseurs issus de JD+ (*package **rjd3modelling***), les ω_k sont calculés entre les jours d'une semaine classique. Ainsi, il y a 5 jours ouvrables (du lundi au vendredi) et 2 jours de week-end (samedi et dimanche).
 - pour REG6, $\omega_k = 1$ car chaque groupe G_i ne contient qu'un jour (du lundi au dimanche)
 - pour REG1, $\omega_k = \frac{5}{2}$ car le groupe 1 G_1 (jours ouvrables) contient les jours du lundi au vendredi et le groupe 0 G_0 contient le samedi et le dimanche.
 - ... selon les configurations des groupes
- Pour les jeux de régresseurs issus des programmes **SAS**, les jours comptabilisés dans les pondérations sont les jours *In* et les jours *Off*.
 - pour REG6, $\omega_k = \frac{1}{8}$ car chaque groupe G_k (pour $k \neq 0$) ne contient qu'un seul jour alors que le groupe 0 G_0 contient 8 jours dans le sens : 1 dimanche en semaine classique (*In*) et 7 jours en semaine férié / vacances (*Off*)
 - pour REG1, $\omega_k = \frac{5}{9}$ car le groupe 1 (jours ouvrables) contient 5 jours : les jours *In* du lundi au vendredi et le groupe 0 G_0 contient le samedi et le dimanche en semaine classique (*In*) et 7 jours en semaine férié / vacances (*Off*).
 - ... selon les configurations des groupes

Les espaces formés par la combinaison de chaque jeu de régresseurs (**RJD** ou **SAS**) sont les mêmes. Mais les coefficients seront différents et interprétés différemment.

Théorie et pratique

Présentation du modèle théorique

Le modèle initial s'écrit :

$$D_t = \sum_{i=1}^7 \alpha_i \times Day_{i,t} \quad (1)$$

Avec α_i l'effet du jour i (au moment t) sur notre variable. On appelle D_t l'effet déterministe du calendrier sur variable à étudier.

Malheureusement, ce modèle n'est pas utilisable directement comme ça car :

- les régresseurs $Day_{i,t}$ sont fortement corrélés (exemple : le nombre de lundi dans un mois vaut toujours entre 3 et 5, comme tous les autres jours)
- les régresseurs sont saisonnier (exemple : en moyenne, il y aura plus de lundi en janvier qu'en février ou qu'en avril)

Aussi on remarque que $\sum_{i=1}^7 Day_{i,t} = NbDays_t$ est constant (par mois) sauf en février.

Pour contrer cela, on va chercher à séparer l'**effet cummulatif du nombre total de jour du mois** de l'**effet net du nombre de type de jour de la semaine** (exemple : nombre de lundi).

On réécrit l'équation en intégrant $NbDays_t$, le nombre de jour total du mois et $\bar{\alpha}$ l'effet moyen d'un type de jour :

$$D_t = \bar{\alpha} \times NbDays_t + \sum_{i=1}^7 \beta_i \times Day_{i,t} \quad (2)$$

Avec $\bar{\alpha} = \frac{1}{7} \sum_{i=1}^7 \alpha_i$ et $\beta_i = \alpha_i - \bar{\alpha}$

On remarque alors que $\sum_{i=1}^7 \beta_i = 0$. Donc $\beta_7 = -\sum_{i=1}^6 \beta_i$ et on peut écrire nos régresseurs en contraste du dimanche (ou de n'importe quel autre jour) :

$$D_t = \bar{\alpha} \times NbDays_t + \sum_{i=1}^6 \beta_i \times (Day_{i,t} - Day_{7,t}) \quad (3)$$

Ce modèle correspond à *peu près* au modèle REG6 mais on peut formuler des hypothèses plus fortes pour créer de nouveaux jeux de régresseurs :

- Si je suppose que $\beta_1 = \beta_2 = \beta_3 = \beta_4 = \beta_5$ et $\beta_6 = \beta_7$, j'obtiens le modèle $D_t = \bar{\alpha} \times NbDays_t + \beta_1 \times (\sum_{i=1}^5 Day_{i,t} - \frac{5}{2}(Day_{6,t} + Day_{7,t}))$ qui correspond au jeu de régresseur REG1.
- Si je suppose que $\beta_1 = \beta_2 = \beta_3 = \beta_4 = \beta_5$, j'obtiens le modèle $D_t = \bar{\alpha} \times NbDays_t + \beta_1 \times (\sum_{i=1}^5 Day_{i,t} - Day_{7,t}) + \beta_6 \times (Day_{6,t} - Day_{7,t})$ qui correspond au jeu de régresseur REG2.
- ...

Finalement quelque soit le jeu de régresseur (regroupement de jour) que l'on choisit, le modèle général s'écrit :

$$D_t = \beta_0 \times LY_t + \sum_{k=1}^n \beta_k \times REC_{n_}AC_{k,t} \quad (4)$$

Avec LY_t la variable relative aux années bissextiles, β_k le coefficient de régression relatif au régresseur $REC_{n_}AC_{k,t}$. $\beta_0 = \bar{\alpha}$ est l'effet moyen de chaque type de jour.

Attention : les régresseurs que l'on considère ($REC_{n_}AC_{k,t}$, LY_t) sont "désaisonnalisés" dans une certaine mesure. On leur a retiré la moyenne de long-terme. Ainsi LY_t diffère de $NbDays_t$ par le retrait de sa moyenne de long-terme par mois et vaut 0 pour tous les mois de l'année sauf pour février pour lequel LY_t vaut -0.25 les années non-bisettes et 0.75 les années bissextiles.

Ainsi le modèle présenté ci-dessus (4), diffère des modèles (1), (2) et (3) par le retrait d'un terme purement saisonnier.

Cette remarque est importante car elle conditionne notre interprétation des coefficients. Le coefficient β_0 n'aura plus la même interprétation que $\bar{\alpha}$ car le régresseur n'est plus le même.

Interprétation des coefficients

Finalement lorsqu'on a notre résultat final, on cherche à interpréter les coefficients finaux et comprendre quel régresseur / jour de la semaine participe.

Tout d'abord, comme on l'a vu entre l'étape (1) et (2), les coefficients que l'on a à commenter sont les β_i (ou β_k quand on fait des groupes) et non les α_i . Donc on ne commente pas l'effet du type de jour i mais sa comparaison par rapport un type de jour moyen. Cela explique que l'on peut avoir des coefficients négatifs pour des types de jour où il y a de l'activité.

Exemple : pour le tableau suivant :

Regresseur	Coefficients	T-Stat	P[T > t]
Lundi	0,0007	0,12	0,9032
Mardi	0,0066	0,89	0,3856
Mercredi	0,0136	1,93	0,2280
Jedi	0,0090	1,25	0,2280
Vendredi	-0,0004	-0,05	0,9632
Samedi	-0,0111	-1,43	0,1715

Donc $\beta_7 = -\sum_{k=1}^6 \beta_k = -0,0184$ pour le coefficient du dimanche.

On aurait envie de commenter : « *L'ajout d'un samedi en plus dans le mois fait baisser l'activité de 0.0111. Cela est contradictoire avec le fait qu'il y a de l'activité le samedi donc un samedi en plus dans le mois devrait faire augmenter l'activité.* »

Cependant ce n'est pas vrai, ici on commente un effet en comparaison de l'effet moyen d'un type de jour moyen. La bonne explication est la suivante : « *Chaque mois a le même nombre de jour. L'ajout d'un samedi dans le mois retire obligatoirement un autre jour du mois. Il y a des jours où l'activité est plus intense qu'un samedi. Donc en moyenne, le jour que l'on retire aurait apporté plus d'activité. L'ajout d'un samedi "en plus" (= à la place d'un jour moyen) dans le mois a un impact négatif sur l'activité.* »

Remarque 1 : Les régresseurs sont désaisonnalisés Comme on l'a vu entre les équations (3) et (4), on retire les moyennes de long-terme. Ainsi les régresseurs ne sont pas EXACTEMENT des nombres de jours mais ce sont des séries désaisonnalisées (sans leur moyenne de long-terme par mois).

Remarque 2 : le choix la variable mise en contraste n'a pas d'importance. Si on repart de l'équation (3), on remarque que le choix du dimanche en contraste est un choix arbitraire. On peut donc réécrire l'équation de REG1 (par exemple) en conséquence :

$$D_t = \bar{\alpha} \times NbDays_t - \frac{1}{5}\beta_7 \times (Day_{6,t} + Day_{7,t} - \frac{2}{5} \sum_{i=1}^5 Day_{i,t})$$

La réestimation de ce modèle donnera un $\beta_7 = \beta_6$ identique au modèle REG1 écrit plus haut et les autres $\beta_i = -\frac{2}{5}\beta_7$ (pour i entre 1 et 5) seront aussi les mêmes.

Remarque 3 : la réalité est plus complexe Ici on a considéré un modèle simpliste. On a considéré que chaque jour de l'année se partageait en 7 catégories (lundi, mardi, ..., dimanche). Seulement dans la réalité, les modèles de calendriers sont plus complexes. Tout d'abord, on peut distinguer les jours *In* (jours ouvrés) et les jours *Off* (jours fériés) : cela nous donne 14 types de jour différents. On peut aussi considérer des modèles personnalisés selon l'activité.

Exemple : dans le transport routier, les camions peuvent rouler toute l'année, jours ouvrés comme fériés. Seulement certains samedis, la circulation des poids-lourds est interdite. Il faudrait idéalement, créer un nouveau type de jour "samedi interdit" pour ces samedis.

Remarques générales

Ordre des opérations

Enfin on peut formuler une remarque sur l'ordre des opérations.

L'opération de calcul des moyennes prend une série (mensuelle ou trimestrielle) et retire sa moyenne par période :

$$\bar{X} = I_1 \times (X - X_mean_1) + I_2 \times (X - X_mean_2) + \dots + I_n \times (X - X_mean_n)$$

avec I_i l'indicatrice de la période i et n le nombre total de période (exemple $n = 12$ pour une fréquence mensuelle).

L'opération de contraste prend 2 séries et en fait une somme pondérée :

$$X_contrast = X + \omega Y$$

Ces deux opérations sont des opérateurs linéaires ainsi on peut alterner ces 2 formules lors du calcul des contrastes :

$$\overline{X + \omega Y} = \bar{X} + \omega \bar{Y}$$

Occurrence du premier de l'an

Les règles de création des calendriers sont stables dans le temps (on sait quel jour tombera le 26 mars dans 450 ans). Ainsi on peut calculer les fréquences des jours de la semaine.

Nombre d'occurrence en 400 ans :

Lundi	Mardi	Mercredi	Jeudi	Vendredi	Samedi	Dimanche
56	58	57	57	58	56	58

Fréquence d'apparition un premier de l'an :

Lundi	Mardi	Mercredi	Jeudi	Vendredi	Samedi	Dimanche
0.14	0.145	0.1425	0.1425	0.145	0.14	0.145

Fréquence de Pâques

On peut classer en 2 catégories les jours fériés français : - ceux qui tombent chaque année à la même date (1er janvier, 25 décembre, ...) - ceux qui tombent chaque année sur le même type de jour (lundi, mardi, ...) mais à des dates différentes (lundi de Pâques, jeudi de l'ascension, ...)

Il existe 3 jours fériés de la seconde catégories et ils dépendent tous les 3 de la date de Pâques : lundi de Pâques, jeudi de l'ascension et lundi de pentecôte.

Seulement la date de Pâques suit le calendrier lunaire. Et la fréquence de Pâques (combinant calendrier grégorien et calendrier lunaire) est de 5700000 ans.

Mais faut-il donc prendre en compte la totalité de la série des dates de Paques pour calculer les moyennes de long-terme ou juste un extrait de quelques siècles voire les années sur lesquelles on effectue nos analyses ?